BANCO RESIDÊNCIA — DOCUMENTO TÉCNICO OFICIAL

Relatório Executivo: Mapeamento Global de Bancos de Questões & Datasets em JSON

Auditoria de Viabilidade, Fragilidade de Coleta, Volumetria e Arquitetura de Ingestão de Exames Médicos

Status: Homologado para Execução **Escopo:** R1, R+, Revalida e Concursos Médicos **Data:** Outubro de 2026

Classificação: Estratégico & Confidencial

1.100.000+
QUESTÕES MAPEADAS

250.000+
DOWNLOAD IMEDIATO JSON

0% Risco WAF
NAS FONTES ABERTAS

100% Gabarito
PADRÃO OURO DEFINITIVO

Síntese Estratégica: Identificou-se que a melhor oportunidade de crescimento do Banco Residência sem qualquer risco de bloqueio anti-bot ou CAPTCHA reside na combinação de **Datasets Públicos em JSON** (HuggingFace/GitHub/Zenodo) e **Portais de Bancas Concursais Oficiais** (assegurados pela Lei de Acesso à Informação).

1 Datasets Públicos em JSON (Download Imediato e Risco Zero)

Estes conjuntos de dados foram compilados, limpos e estruturados por grupos acadêmicos e comunidades de Inteligência Artificial Médica. Não há barreiras de login, IP throttling nem desafios de segurança.

DATASET / REPOSITÓRIO	ORIGEM	VOLUMETRIA	FORMATO DO DADO	TIPO DE ACESSO	CLASSIFICAÇÃO
medbench-brasil Precisa Saúde	Revalida INEP + ENAMED	**Milhares** (todas edições)	`.json` por edição (A–D/E, gabaritos)	GitHub / NPM	RISCO ZERO (ABERTO)
Larxel/healthqa-br HuggingFace Datasets	ENARE Residência + Revalida (2011–2025)	**30.000+** questões	`.parquet` / `.json` (metadados de temas)	HuggingFace API / Download direto	RISCO ZERO (ABERTO)
recogna-nlp/drbodebench Laboratório Recogna	FUVEST (USP) + Revalida Oficial	**Milhares** curadas	`questoes-Revalida+Fuvest.json`	Download direto HTTP	RISCO ZERO (ABERTO)
AKCIT/MedPT Corpus Médico BR	104 especialidades clínicas no Brasil	**384.095** pares Q&A	`.jsonl` / `.parquet` com condutas clínicas	HuggingFace Datasets	RISCO ZERO (ABERTO)
MedMCQA Indian Medical PG / AIIMS	Exames Oficiais de Residência Médica	**194.000** questões	`.jsonl` com comentários detalhados	GitHub / HuggingFace	RISCO ZERO (ABERTO)
MedQA (USMLE) Jin et al.	USMLE Step 1, 2 CK e 3	**61.000** casos clínicos	`.jsonl` com 4–5 alternativas e gabarito	GitHub Repo	RISCO ZERO (ABERTO)

DATASET / REPOSITÓRIO	ORIGEM	VOLUMETRIA	FORMATO DO DADO	TIPO DE ACESSO	CLASSIFICAÇÃO
HeadQA (MIR Espanha) Exame Oficial MIR	Residência Médica da Espanha (padrão Brasil)	**~8.000** questões	`.json` com 5 opções (A–E) e gabaritos	HuggingFace Datasets	RISCO ZERO (ABERTO)

Comando de Carga Imediata em Python (Hugging Face Datasets):

```python
# Ingestão direta em lote sem necessidade de web scraping
from datasets import load_dataset
import json

ds = load_dataset("Larxel/healthqa-br")
with open("data/enare_revalida_extraido.json", "w", encoding="utf-8") as f:
    json.dump([item for item in ds["train"]], f, ensure_ascii=False, indent=2)
```

2 Serviços B2B e Questions-as-a-Service (QaaS) em JSON

Plataformas desenvolvidas para entrega programática de dados para edtechs, cursinhos e aplicativos de medicina.

Mediciner API (api.mediciner.com.br)

API REST B2B

Infraestrutura especializada em alimentação de bancos de questões. Conta com **97.000 questões** estruturadas de R1, R3, ENARE, Revalida e ENAMED.

ENDPOINTS PRINCIPAIS	ESTRUTURA RETORNADA	AUTENTICAÇÃO	COMPLEXIDADE DE INGESTÃO
`GET /v1/questoes` `GET /v1/provas`	ID, enunciado, alternativas A–E, gabarito e comentários	Bearer API Key	MÍNIMA (JSON NATIVO)

OrganizaMed Pro (organizamedpro.com.br)

BANCOS R1/R+ & API REST

Fornece pacotes completos de bancos de dados prontos (R1 e R+) em formato JSON e CSV, além de API REST de provas e módulo add-on de comentários por alternativa.

VOLUMETRIA ESTIMADA	FORMATO DE ENTREGA	METADADOS INCLUSOS	COMPLEXIDADE
~60.000 questões	JSON / CSV / API REST	Tema, subfoco, banca e ano	PRONTO PARA BANCO

3 Plataformas Web & Mobile com Endpoints REST / GraphQL

Plataformas que rodam Single Page Applications (SPAs) ou aplicativos nativos em Flutter/React Native. Em muitas delas, as chamadas móveis não sofrem com proteções agressivas de Cloudflare Turnstile.

PLATAFORMA	VOLUMETRIA	ARQUITETURA DE API	COMPORTAMENTO DO GABARITO	VIABILIDADE DE COLETA
MedCof (QBank) qbank.grupomedcof.com.br	**120.000+**	SPA React / GraphQL / REST JSON	Disponível no fluxo de resolução e prova	MÉDIA (REQUER SESSÃO)
MedQ app.medq.com.br / Apps	**150.000+**	Mobile Backend REST / JSON	Entregue em pacotes paginados de questões	MÉDIA (API ABERTA NO APP)
Hardwork Medicina hardworq.com.br	**~75.000**	REST API JSON estruturado	Gabarito oficial + estatísticas de acerto	MÉDIA (SESSÃO SIMPLES)
Medcards smartflashcards.com.br	**~40.000**	Sync de Baralhos / QBank JSON	Gabarito vinculado ao flashcard	MÉDIA (TOKEN DE ESTUDANTE)
EstudeGrátis estudegratis.com.br	**~35.000** (médicas)	AJAX / JSON sem WAF agressivo	Acesso livre sem login obrigatório	MUITO ALTA (ZERO RISCO)
QuestMed & MedBrave Mapeadas no Repositório	**140.000+** (somadas)	REST API e bundles SPA	Gabaritos presentes nos objetos de questão	ALTA (PIPELINES JÁ CRIADOS)

4 Portais de Bancas Concursais Oficiais (Lei de Acesso à Informação)

Bancas públicas e instituições federais/estaduais são obrigadas pela Lei nº 12.527/2011 a manter os cadernos de provas e gabaritos definitivos (retificados após recursos) disponíveis publicamente:

- **ENARE (EBSERH / FGV / AOCP):** Provas nacionais unificadas anuais de R1 e R+ com gabaritos definitivos diretos em PDF
- **PSU-MG (AREMG):** Maior processo seletivo unificado de MG (mais de 60 hospitais); cadernos e gabaritos de 2014 a 2026.

vetorial.

• **AMRIGS:** Exame unificado do Rio Grande do Sul, Santa Catarina, MT, MS e RO com cadernos e gabaritos oficiais.

• **PCI Concursos:** Maior acervo público nacional com links diretos de CDN (`arquivo.pciconcursos.com.br`) sem CAPTCHA.

5 Matriz Geral de Priorização Estratégica

FONTE / PLATAFORMA	CATEGORIA	VOLUME	FORMATO	PROTEÇÃO ANTI-BOT	RECOMENDAÇÃO TÉCNICA
medbench-brasil	Dataset Aberto	15.000+	JSON Nativo	Nenhuma (GitHub)	**Prioridade 1 — Baixar Imediato**
HealthQA-BR (ENARE/Revalida)	Dataset Aberto	30.000+	JSON / Parquet	Nenhuma (HuggingFace)	**Prioridade 1 — Baixar Imediato**
drbodebench (FUVEST/USP)	Dataset Aberto	8.000+	JSON Nativo	Nenhuma (HuggingFace)	**Prioridade 1 — Baixar Imediato**
MedMCQA (Residência PG)	Dataset Aberto	194.000	JSONL	Nenhuma (HuggingFace)	**Prioridade 1 — Base para IA/TRI**
PCI Concursos & Bancas LAI	Repositório Oficial	90.000+	PDF Vetorial	Nenhuma (Legal)	**Prioridade 2 — Parser Contínuo**
EstudeGrátis	Portal Concursos	35.000	AJAX / JSON	Baixa	**Prioridade 3 — Extração por Script**
Mediciner / OrganizaMed	QaaS B2B	150.000+	REST API JSON	API Key	**Prioridade 3 — Parceria / Ingestão**
MedQ / QBank MedCof	SPA / Mobile App	270.000+	REST / GraphQL	Autenticação Usuário	**Prioridade 4 — Sessão Controlada**
Estratégia MED / Medway / Sanar	Grandes Cursinhos	300.000+	WAF / Criptografado	Cloudflare Turnstile	**Inviável — Alto Risco de Bloqueio**

6 Arquitetura de Ingestão no Banco Residência

O pipeline de ingestão deve unificar todas as fontes com verificação de integridade e deduplicação automática contra a base do Supabase:

Etapas do Motor de Ingestão:

1. **Download e Staging:** Arquivos JSON são gravados na pasta local `data/staging/` sem impactar o banco de produção.
2. **Normalização de Schema:** Mapeamento universal para os campos da interface `Question` (enunciado, alternativas A–E, gabarito e comentários).
3. **Deduplicação Canônica:** Criação de hash MD5/SHA256 do texto do enunciado limpo (sem pontuação, acentuação ou espaços duplicados) para detectar se a questão já existe no banco.
4. **Homologação do Gabarito:** Se a questão já existir mas estiver com gabarito nulo, o gabarito oficial da fonte primária é atualizado no Supabase. Se for nova, a questão é criada.